01 -intro ti ML

Tags	
Course	Machine Lerning
Confidence	Not Confident
Materials	02 Intro to ML.pptx.pdf
Last Edited	7 October 2026 10:38

Dispensa di Studio: Fondamenti di Machine Learning (Modulo II)

MODULO II: Concetti Fondamentali, Modellazione Lineare e Ottimizzazione basata sul Gradiente

1. Concetti Chiave e Definizioni Formali

- **Definizione Formale di Apprendimento Automatico (Tom M. Mitchell, 1997):** Un programma per calcolatore apprende da un'esperienza E rispetto a una classe di compiti (*tasks*) T e a una misura di prestazione P, se le sue prestazioni nel completare i compiti in T, misurate tramite P, migliorano con l'esperienza E.

$$\text{Esperienza } (E) \xrightarrow{\text{Migliora}} \text{Prestazione } (P) \quad \text{nel Task } (T)$$

- **Tassonomia dei Paradigmi di Apprendimento:**
  1. **Supervised Learning (Apprendimento Supervisionato):** Paradigma *task-driven* in cui il modello riceve in ingresso una collezione di campioni associati a etichette esplicite (target) e apprende una funzione di mappatura per predire l'etichetta su dati futuri non visti.
  2. **Unsupervised Learning (Apprendimento Non Supervisionato):** Paradigma *data-driven* in cui il dataset è privo di etichette e il modello mira a scoprire strutture latenti, relazioni o raggruppamenti (*cluster*) intrinseci nei dati.

3. **Reinforcement Learning (Apprendimento per Rinforzo):** Paradigma basato sull'interazione dinamica tra agente e ambiente, in cui l'agente apprende la sequenza di azioni ottimali per massimizzare una ricompensa cumulativa attraverso un processo di prova ed errore.

- **Formalizzazione Matematica del Task (T):**
  I compiti affrontati dal Machine Learning descrivono il modo in cui il sistema processa un singolo esempio. Ogni esempio è rappresentato da un **vettore delle feature** $\mathbf{x} \in \mathbb{R}^n$, dove ogni coordinata x_i esprime una specifica caratteristica quantitativa o qualitativa dell'osservazione.
  - **Classificazione:** Mappatura da un vettore di feature $\mathbf{x} \in \mathbb{R}^n$ a una categoria discreta $y \in \{1, \dots, C\}$ (es. identificazione di immagini di cani o gatti, rilevamento mail spam).
  - **Regressione:** Predizione di un valore numerico continuo $y \in \mathbb{R}$ a partire dall'input $\mathbf{x}$ (es. stima del prezzo di un immobile in base alla superficie).
  - **Sintesi e Campionamento:** Generazione di nuovi campioni sintetici appartenenti alla medesima distribuzione di probabilità dei dati di addestramento (es. modelli di diffusione come *Stable Diffusion*).
  - **Stima della Probabilità (Density Estimation):** Apprendimento esplicito o implicito della funzione di densità di probabilità sottostante ai punti del dataset.
- **Misura delle Prestazioni (P) e Diagnostica di Classificazione:**
  La valutazione quantitativa dell'abilità di un modello viene effettuata tramite metriche matematiche trasversali.

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

Dove TP indica i Veri Positivi, TN i Veri Negativi, FP i Falsi Positivi (Errori di Tipo I) e FN i Falsi Negativi (Errori di Tipo II).

- **Paradosso dell'Accuracy nei Dataset Sbilanciati:** In presenza di classi sbilanciate, l'accuracy risulta fuorviante. Se un dataset contiene 9900 campioni negativi e 100 positivi, un classificatore banale che predice sempre la classe negativa ottiene un'accuracy del 99% ($\frac{9900}{10000}$), pur fallendo nel rilevare la totalità dei casi positivi di interesse.
- **Precision (Precisione):** Rapporto fra i veri positivi e il totale degli elementi classificati come positivi dal modello. Risponde alla domanda *"Quanti degli*

elementi selezionati sono effettivamente rilevanti?":

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall (Richiamo / Sensibilità):** Rapporto fra i veri positivi e il totale degli elementi realmente positivi nel dataset. Risponde alla domanda *"Quanti degli elementi rilevanti sono stati selezionati?"*:

$$\text{Recall} = \frac{TP}{TP + FN}$$

---

2. Trattazione Teorica Estesa

A. Rappresentazione dei Dati e Representation Learning

L'efficacia di un modello di Machine Learning dipende dalla forma e dalla struttura con cui i dati di input vengono forniti al sistema.

L'evoluzione dei paradigmi di elaborazione dei dati si articola in quattro stadi fondamentali:

1. **Sistemi basati su Regole (Rule-based Systems):** Il programmatore umano definisce sia la logica che le regole codificate manualmente; l'input viene elaborato dal programma rigido per generare l'output.
2. **Machine Learning Classico:** L'esperto di dominio progetta e individua manualmente le caratteristiche salienti (*hand-designed features*). Il modello di ML apprende esclusivamente la mappatura finale da tali feature all'output.
3. **Representation Learning (Apprendimento delle Rappresentazioni):** Il sistema riceve feature grezze o poco elaborate e apprende autonomamente la trasformazione e la rappresentazione ottimale dei dati prima di effettuare la stima.
4. **Deep Learning (Apprendimento Profondo):** Architettura gerarchica costituita da una sequenza di strati (*layers*) in cui i primi livelli apprendono feature semplici (es. margini, spigoli) e gli strati successivi combinano tali rappresentazioni per comporre concetti astratti di alto livello.

B. Il Modello di Regressione Lineare

La regressione lineare modella la relazione tra un vettore di variabili indipendenti $\mathbf{x} \in \mathbb{R}^n$ e una variabile dipendente continua $\hat{y} \in \mathbb{R}$ mediante la seguente combinazione lineare:

$$\hat{y} = \mathbf{w}^T \mathbf{x} + b = \sum_{j=1}^{n} w_j x_j + b$$

- **Vettore dei Pesi ($\mathbf{w} \in \mathbb{R}^n$):** Rappresenta i parametri del modello che regolano l'impatto di ciascuna feature x_j sulla stima finale.
  - Un valore elevato in modulo $|w_j|$ indica che la feature x_j esercita un'influenza marcata sulla predizione.
  - Un valore $w_j > 0$ indica una correlazione diretta; un valore $w_j < 0$ indica una relazione inversamente proporzionale.
- **Intercetta / Bias ($b \in \mathbb{R}$):** Modella il valore atteso dell'output quando tutte le feature x_j sono nulle, consentendo alla retta o iperpiano di traslare nello spazio senza essere vincolata a passare per l'origine.

C. Criteri di Ottimizzazione e Funzione di Perdita

Per addestrare il modello lineare si definisce una misura quantitativa dell'errore. La metrica fondamentale adottata nella regressione è il **Mean Squared Error (MSE)** calcolato su m campioni:

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^{m} (\hat{y}_i - y_i)^2$$

- **Distinzione Formale tra Loss Function e Cost Function:**
  - **Loss Function (Funzione di Perdita):** Definisce l'errore commesso su un *singolo* esempio del dataset: $L(\hat{y}_i, y_i) = (\hat{y}_i - y_i)^2$.
  - **Cost Function / Objective Function (Funzione di Costo / Obiettivo):** Rappresenta la media dell'errore calcolata sull'intero dataset di addestramento: $J(\mathbf{w}, b) = \frac{1}{m} \sum_{i=1}^{m} L(\hat{y}_i, y_i)$.

D. Ottimizzazione basata sul Gradiente (Gradient Descent)

L'addestramento dei modelli si configura come un problema di minimizzazione della funzione di costo.

Per funzioni a una singola variabile $y = f(x)$, la derivata $f'(x)$ esprime il tasso di variazione istantaneo. Sfruttando l'espansione in serie di Taylor del primo ordine per un piccolo incremento ϵ:

$$f(x + \epsilon) \approx f(x) + \epsilon f'(x)$$

Per ridurre il valore della funzione, si aggiorna la posizione nella direzione opposta al segno della derivata:

$$x^{(k+1)} = x^{(k)} - \epsilon \cdot \text{sign}(f'(x^{(k)})) \implies f(x^{(k+1)}) < f(x^{(k)})$$

In contesti multivariati $\mathbf{x} \in \mathbb{R}^n$, la generalizzazione della derivata è il **vettore gradiente** $\nabla_{\mathbf{x}} f(\mathbf{x})$, che raccoglie le derivate parziali rispetto a ciascuna coordinata:

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

Il gradiente indica la direzione di massima crescita (*steepest ascent*) della funzione. Di conseguenza, per minimizzare la funzione si esegue un aggiornamento nella direzione opposta al gradiente mediante l'equazione del **Gradient Descent Multivariato**:

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \alpha \nabla_{\mathbf{w}} J(\mathbf{w}^{(k)})$$

Dove $\alpha > 0$ rappresenta il **Learning Rate** (tasso di apprendimento), iperparametro che definisce l'ampiezza dello passo effettuato ad ogni iterazione.

- **Caratterizzazione dei Punti Critici ($\nabla f(\mathbf{x}) = \mathbf{0}$):**
  - **Minimo Globale:** Punto in cui la funzione assume il valore minimo assoluto sull'intero dominio.
  - **Minimo Locale:** Punto in cui la funzione assume un valore inferiore a tutti i punti del suo intorno, pur non essendo il minimo assoluto.
  - **Punto di Sella (Saddle Point):** Punto critico in cui la curvatura della funzione è positiva lungo alcune direzioni e negativa lungo altre.

Nelle reti neurali profonde non esistono soluzioni in forma chiusa per azzerare il gradiente ($\nabla_{\mathbf{w}} \text{MSE} = 0$); pertanto si ricorre unicamente a metodi di

ottimizzazione iterativi basati sul gradiente.

---

3. Focus su Schemi, Diagrammi e Immagini (Decostruzione Analitica)

1. **Analisi della Tassonomia degli Algoritmi di Apprendimento (Slide 1):**
   - *Rappresentazione:* Diagramma ad albero gerarchico che declina il nodo radice *"Machine Learning"* nei tre rami primari *"Supervised"*, *"Unsupervised"* e *"Reinforcement"*.
   - *Decostruzione e Flusso Logico:*
     - Il ramo *Supervised* è annotato come *Task Driven (Predict next value)*, evidenziando come la presenza delle etichette orienti la funzione obiettivo verso la stima di un target ben definito.
     - Il ramo *Unsupervised* è annotato come *Data Driven (Identify Clusters)*, indicando che la struttura viene estratta direttamente dalla distribuzione spaziale dei punti.
     - Il ramo *Reinforcement* è annotato come *Learn from mistakes*, rappresentando il ciclo iterativo di ricompensa/punizione inviato dall'ambiente in risposta alle azioni dell'agente.
2. **Decostruzione della Matrice di Confusione e dell'Accuracy Paradox (Slide 3, 4):**
   - *Rappresentazione:* Matrice di confusione 2×2 applicata alla classificazione binaria di immagini ("HOTDOG" vs "NOT HOTDOG") e relativa tabella con sbilanciamento delle classi.
   - *Analisi Componenti:*
     - *True Negative (TN):* Immagine di una pizza classificata come "NOT HOTDOG".
     - *False Positive (FP):* Immagine di un cane razza Dachshund (Bassotto) travestito da hotdog classificata erroneamente come "HOTDOG".
     - *False Negative (FN):* Immagine di un cibo con condimento e würstel classificata erratamente come "NOT HOTDOG".
     - *True Positive (TP):* Immagine di un classico hotdog classificata correttamente come "HOTDOG".
   - *Analisi Matematica della Tabella Sbilanciata:*
     La tabella riporta 9900 Negativi Reali e 100 Positivi Reali. L'output del

modello predice 0 per tutti i campioni.
$TP = 0, FP = 0, TN = 9900, FN = 100.$
$\text{Accuracy} = \frac{0+9900}{0+0+9900+100} = \frac{9900}{10000} = 99.0\%.$
L'accuracy cela l'incapacità totale del modello nel rilevare la classe positiva ($\text{Recall} = \frac{0}{100} = 0\%$).

3. **Decostruzione del Diagramma degli Insiemi per Precision e Recall (Slide 4):**
   - *Rappresentazione:* Diagramma di Venn/insiemistico contenente i punti dello spazio dei dati.
   - *Decostruzione dei Componenti:*
     - Lo sfondo verticale verde a sinistra raccoglie gli *elementi rilevanti* (campioni realmente positivi).
     - Il cerchio centrale delimita gli *elementi selezionati* (campioni che il classificatore ha predetto come positivi).
     - L'intersezione tra lo sfondo verde e l'interno del cerchio costituisce il semicerchio verde dei *True Positives* (TP).
     - La metà destra del cerchio (sfondo grigio dei campioni realmente negativi) costituisce il semicerchio rosso dei *False Positives* (FP).
     - A sinistra del cerchio, l'area verde non coperta dal cerchio rappresenta i *False Negatives* (FN).
   - *Formulazione Visiva:*
     - $\text{Precision} = \frac{\text{Semicerchio Verde } (TP)}{\text{Cerchio Intero } (TP+FP)}$.
     - $\text{Recall} = \frac{\text{Semicerchio Verde } (TP)}{\text{Rettangolo Verde } (TP+FN)}$.
4. **Analisi del Trasferimento dello Spazio delle Feature: Cartesiano vs Polare (Slide 5):**
   - *Rappresentazione:* Due grafici a dispersione (*scatterplot*) affiancati che illustrano la separabilità di un dataset.
   - *Decostruzione Passo-Passo:*
     - *Coordinate Cartesiane* (x, y)*:* Il dataset è composto da un cluster circolare denso al centro (punti blu) circondato da un anello concentrico esterno (triangoli verdi). In questo spazio, un classificatore lineare non può tracciare una retta per separare le due

classi; il problema richiede un confine di decisione non lineare di secondo grado ($x^2 + y^2 = r^2$).

- *Coordinate Polari* (r, θ)*:* Applicando la trasformazione di coordinate $r = \sqrt{x^2 + y^2}$ e $\theta = \arctan(y/x)$, il dataset viene proiettato nel nuovo spazio delle feature. I punti blu si concentrano lungo valori bassi dell'asse del raggio r, mentre i triangoli verdi si collocano a valori di r elevati. Nel piano polare, il confine di decisione diventa una retta verticale parallela all'asse θ, rendendo il problema **linearmente separabile**.

5. **Decostruzione dello Schema a Blocchi della Rappresentazione dei Dati (Slide 5):**
   - *Rappresentazione:* Diagramma a quattro colonne comparative che mostrano il livello di astrazione automatica nei diversi paradigmi.
   - *Flussi Logici:*
     - *Rule-based:* $\text{Input} \longrightarrow \text{Hand-designed program} \longrightarrow \text{Output}.$
     - *Classic ML:* $\text{Input} \longrightarrow \text{Hand-designed features} \longrightarrow \text{Mapping from features} \longrightarrow \text{Output}.$
     - *Representation Learning:* $\text{Input} \longrightarrow \text{Features} \longrightarrow \text{Mapping from features} \longrightarrow \text{Output}$ (i blocchi scuri indicano componenti appresi dal modello).
     - *Deep Learning:* $\text{Input} \longrightarrow \text{Simple features} \longrightarrow \text{Additional layers of abstract features} \longrightarrow \text{Mapping from features} \longrightarrow \text{Output}.$
6. **Analisi della Gerarchia dei Filtri nelle Reti Convoluzionali (CNN) (Slide 5):**
   - *Rappresentazione:* Schema di un'architettura tipo AlexNet e visualizzazione dell'attivazione dei filtri ai vari livelli di profondità.
   - *Decostruzione Analitica:*
     - *Conv 1 (Primo Livello Convoluzionale):* I filtri apprendono pattern elementari ad alta frequenza spaziale, come bordi orientati (orientations), gradienti di colore e texture semplici.
     - *Conv 3 (Livello Intermedio):* I filtri combinano i bordi per rilevare pattern complessi, griglie, motivi circolari e consistenze tessili.

- *Conv 5 (Livello Profondo):* I filtri si attivano in presenza di parti strutturate di oggetti complessi, quali volti di animali, quadranti di orologi, ruote di automobili.
- *Fc8 (Strato Fully Connected Finale):* Le attivazioni mappano rappresentazioni semantiche complete appartenenti alle classi di output (es. galline, imbarcazioni).

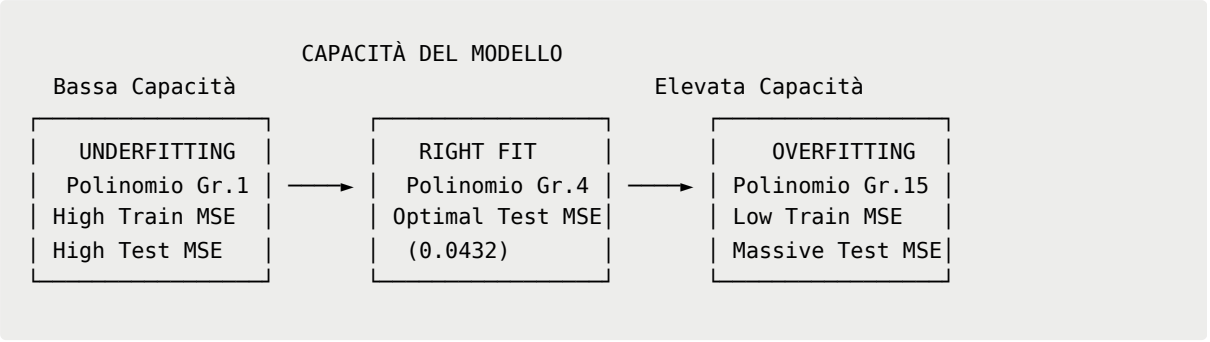
7. **Analisi del Grafico di Ottimizzazione del Singolo Parametro (Slide 12, 15):**
   - *Rappresentazione:* Funzione parabolica di costo $J(w_1) = \text{MSE}_{(\text{train})}$ e relativo fitting lineare sui punti dati.
   - *Decostruzione:*
     - Il grafico a sinistra mostra i punti sperimentali (x_1, y) e la retta d'interpolazione $\hat{y} = w_1 x_1 + b$.
     - Il grafico a destra rappresenta la curva quadratica del MSE in funzione del peso w_1. Il minimo della parabola corrisponde al valore di $w_1 \approx 1.5$ in cui il gradiente si azzera ($\nabla_w \text{MSE} = 0$), garantendo la retta che minimizza la somma dei quadrati dei residui.

---

4. Capacità del Modello, Overfitting, Regolarizzazione e Normalizzazione

A. Trade-off tra Underfitting e Overfitting

Il fine primario dell'apprendimento automatico non è la memorizzazione del training set, ma la **generalizzazione** su campioni non visti (*unseen data*).



- **Underfitting (Bassa Capacità):** Il modello è troppo semplice per catturare la struttura fondamentale dei dati. Si registra un errore elevato sia sul dataset di addestramento che su quello di test.
- **Overfitting (Alta Capacità):** Il modello ha un'eccessiva capacità ed apprende il rumore e le fluttuazioni casuali del training set. Si ottiene un errore di

addestramento quasi nullo ma un errore di test estremamente elevato.

- *Citazione di John von Neumann: "With four parameters I can fit an elephant, and with five I can make him wiggle his trunk"*.

B. Tecniche di Regolarizzazione

La regolarizzazione è qualsiasi modifica apportata a un algoritmo di apprendimento con lo scopo espresso di ridurne l'errore di generalizzazione, senza ridurne l'errore di addestramento.

1. **Weight Decay (Regolarizzazione L_2):**
   Inibisce la crescita esagerata dei pesi aggiungendo una punizione proporzionale alla norma euclidea al quadrato del vettore dei parametri $\boldsymbol{\theta}$:

$$J(\boldsymbol{\theta}) = \text{MSE}_{\text{train}} + \lambda \|\boldsymbol{\theta}\|_2^2 = \text{MSE}_{\text{train}} + \lambda \sum_j w_j^2$$

Dove $\lambda \geq 0$ è l'iperparametro di regolarizzazione.

- *Spiegazione tramite Matrice Hessiana (H):*
  La matrice Hessiana contiene le derivate parziali di secondo ordine e descrive la curvatura della superficie di perdita. L'introduzione della regolarizzazione L_2 modifica la matrice Hessiana della perdita in:

$$H = H_{\text{MSE}} + \lambda I$$

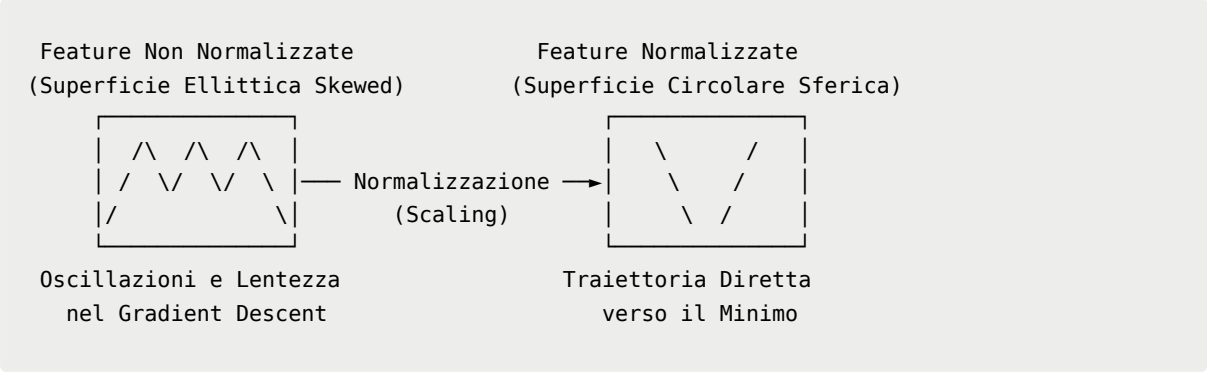
L'aggiunta della matrice identità scalata da λI garantisce che tutti gli autovalori dell'Hessiana vengano traslati verso l'alto di una quantità λ, stabilizzando numericamente l'inversione della matrice e rendendo la superficie di costo meglio condizionata (meno ripida o irregolare).

1. **Dataset Augmentation (Aumento dei Dati):**
   Consiste nell'espandere artificialmente il dataset introducendo trasformazioni realistiche sui campioni originali per costringere il modello ad apprendere invarianze:
   - *Iniezione di Rumore:* Aggiunta di rumore Gaussiano leggero alle feature di input.
   - *Trasformazioni Geometriche:* Operazioni di ritaglio (*Cropping*), ribaltamento speculare (*Flipping*), rotazione (*Rotation*) e traslazione.

- *Trasformazioni Cromatiche:* Alterazione della luminosità (*Brightness Adjust*), contrasto o saturazione.
- *Cancellazione Parziale (Erasure):* Rimozione casuale di porzioni di immagine (*Cutout*).

C. Normalizzazione dei Dati

Quando le feature presentano scale numeriche differenti (es. reddito espresso in decine di migliaia e età espressa in unità), le curve di livello della superficie di perdita assumono una conformazione fortemente ellittica e schiacciata. In tale contesto, il Gradient Descent manifesta un andamento oscillatorio rigido e convergenza lenta.



- **Min-Max Scaling:** Mappa i valori delle feature all'interno dell'intervallo chiuso $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Limite: Estremamente sensibile alla presenza di valori anomali (*outliers*).

- **Z-Score Standardization (Standardizzazione):** Trasforma la distribuzione della feature in modo da avere media nulla ($\mu = 0$) e deviazione standard unitaria ($\sigma = 1$):

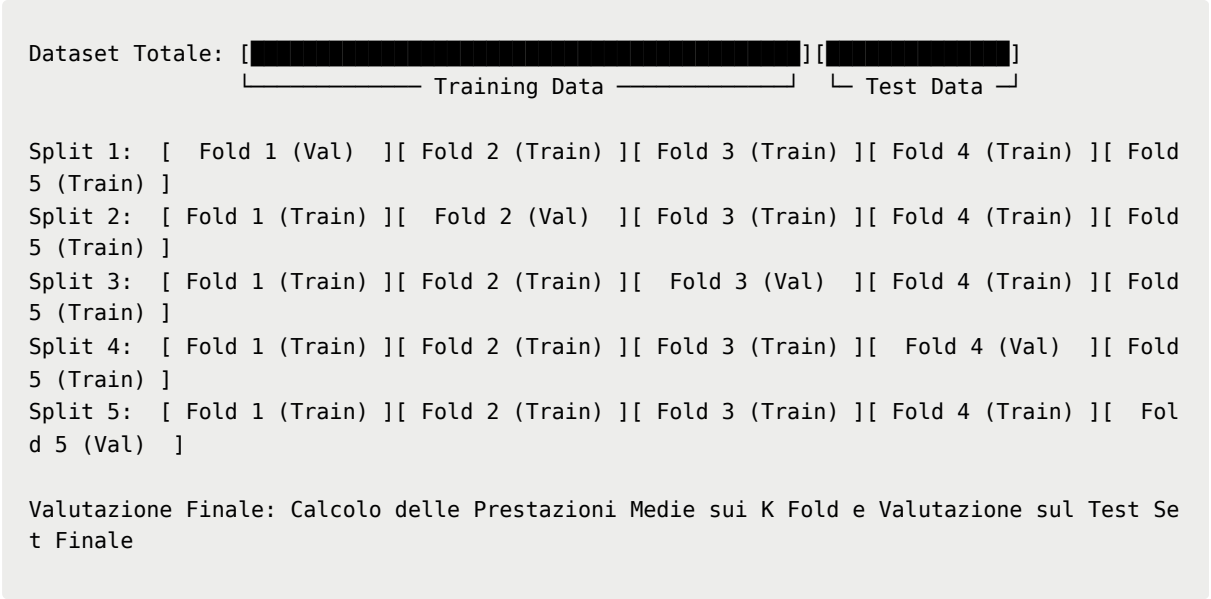
$$x' = \frac{x - \mu}{\sigma}$$

D. Validazione e K-Fold Cross-Validation

Per configurare correttamente gli iperparametri (es. learning rate α, coefficiente di regolarizzazione λ) senza contaminare il test set, il dataset viene ripartito in

tre sottoinsiemi disgiunti: **Train Set** (70-80%), **Validation Set** (10-15%) e **Test Set** (10-15%).

Quando la dimensione totale del dataset è limitata, si impiega la tecnica della **K-Fold Cross-Validation**:



1. Il dataset di addestramento viene suddiviso in K partizioni (*fold*) di eguale dimensione.
2. Il modello viene addestrato K volte; a ciascuna iterazione, $K-1$ fold vengono utilizzati come training set e il fold rimanente funge da validation set.
3. La prestazione finale stimata corrisponde alla media delle metriche calcolate nelle K iterazioni.

- **Vantaggi e Svantaggi:** Massimizza l'utilizzo dei dati disponibili e riduce il bias di campionamento; tuttavia comporta un costo computazionale pari a K volte l'addestramento standard.

---

5. Esempi Applicativi e Note di Approfondimento Didattico

Esempio Numerico Svolto: Passaggio di Aggiornamento del Gradient Descent

Si consideri un modello di regressione lineare con una singola feature e bias nullo: $\hat{y} = w \cdot x$.
Sia dato un dataset composto da un unico campione di addestramento

$(x^{(1)}, y^{(1)}) = (2.0, 5.0)$.
Sia il peso iniziale $w^{(0)} = 1.0$ e il learning rate $\alpha = 0.1$.

1. **Calcolo della Predizione:**

$$\hat{y}^{(1)} = w^{(0)} \cdot x^{(1)} = 1.0 \cdot 2.0 = 2.0$$

1. **Calcolo della Loss (MSE su singolo campione):**

$$L(w) = (\hat{y}^{(1)} - y^{(1)})^2 = (2.0 - 5.0)^2 = (-3.0)^2 = 9.0$$

1. **Calcolo del Gradiente della Loss rispetto al Peso w:**

$$\frac{\partial L}{\partial w} = 2 \cdot (\hat{y}^{(1)} - y^{(1)}) \cdot x^{(1)} = 2 \cdot (2.0 - 5.0) \cdot 2.0 = 2 \cdot (-3.0) \cdot 2.0 = -12.0$$

1. **Aggiornamento del Peso tramite Gradient Descent:**

$$w^{(1)} = w^{(0)} - \alpha \frac{\partial L}{\partial w} = 1.0 - 0.1 \cdot (-12.0) = 1.0 + 1.2 = 2.2$$

1. **Verifica del Miglioramento nella Predizione Successiva:**

$$\hat{y}^{(1)}_{\text{nuova}} = 2.2 \cdot 2.0 = 4.4 \implies L_{\text{nuova}}(w) = (4.4 - 5.0)^2 = (-0.6)^2 = 0.36$$

L'errore è sceso da 9.0 a 0.36 in un singolo passo di ottimizzazione.